
Análisis y Pronóstico del Tráfico Web en Wikipedia mediante Modelos Clásicos y Modernos de Series de Tiempo

Beristain Cuecuecha Luis Eduardo, Xochipa Meneses Valeria Yaremi

Instituto Politécnico Nacional

Unidad Profesional Interdisciplinaria de Ingeniería Campus Tlaxcala

Series de Tiempo

Dr. Jesús García Ramírez

lberistainC2100@alumno.ipn.mx

Abstract

El presente proyecto describe el análisis exploratorio y pronóstico del tráfico web diario en páginas de Wikipedia, haciendo uso del conjunto de datos *Web Traffic Time Series Forecasting* publicado en la plataforma Kaggle. El dataset contiene registros históricos de visitas diarias para aproximadamente 145,000 páginas de Wikipedia en múltiples idiomas, cubriendo un periodo de 550 días entre julio de 2015 y enero de 2017. El objetivo del proyecto fue identificar los patrones temporales dominantes presentes en las series de tiempo y construir modelos de pronóstico que permitieran predecir el volumen de visitas futuras, comparando su precisión y escalabilidad. La metodología se estructuró en tres partes, un análisis exploratorio mediante descomposición estacional, pruebas de estacionariedad y estudio de autocorrelación; la implementación de modelos estadísticos clásicos (SARIMA y Holt-Winters); y la exploración de enfoques modernos basados en aprendizaje automático (LightGBM global y Prophet). La evaluación se empleó el Error Porcentual Absoluto Medio Simétrico (SMAPE), complementado con RMSE y MAE. Los resultados mostraron que los modelos clásicos capturaron de manera asertiva la estacionalidad semanal en series individuales de alto tráfico, por otra parte, el modelo global LightGBM logró escalar al conjunto completo de series obteniendo una buena precisión.

1. Introducción

El análisis y pronóstico de series de tiempo constituye uno de los problemas más estudiados en estadística aplicada e inteligencia artificial, con aplicaciones que abarcan desde la economía y las finanzas hasta la ingeniería y la salud pública. Para nuestro contexto de plataformas web de gran escala, la capacidad de predecir con precisión el volumen de tráfico futuro tiene implicaciones directas sobre la planificación de infraestructura, la asignación eficiente de recursos computacionales y la detección oportuna de fenómenos virales o eventos de interés masivo [1]. Wikipedia, como la enciclopedia colaborativa más grande del mundo, su tráfico muestra de manera casi inmediata el interés colectivo de millones de usuarios en torno a eventos globales, figuras públicas, descubrimientos científicos y sucesos culturales, lo que convirtió sus series de visitas en un indicador indirecto del comportamiento informacional de la humanidad [2].

El conjunto de datos *Web Traffic Time Series Forecasting*, liberado por el equipo de ingeniería de Wikimedia a través de la plataforma Kaggle en 2017, presentó un desafío técnico de considerable complejidad. El dataset contuvo aproximadamente 145,000 series temporales independientes, cada una correspondiente a una combinación única de artículo, idioma, tipo de acceso y tipo de agente.

La escala masiva hizo que el modelado individual con métodos estadísticos clásicos como ARIMA o sus variantes estacionales, entrenar y optimizar un modelo por serie habría requerido recursos computacionales prohibitivos [3].

Frente a este escenario, el presente proyecto se planteó una metodología de análisis estadístico clásico con la escalabilidad de los modelos modernos de aprendizaje automático. Se modelaron de forma individual las páginas de muy alto tráfico donde existió suficiente señal estructural para justificar modelos parametrizados (SARIMA, Holt-Winters), y se aplicó un modelo global de gradiente boosting para el grueso del dataset, construyendo características derivadas de los rezagos temporales, estadísticas de ventana deslizante, variables de calendario y metadatos de las páginas.

2. Trabajos Relacionados

Makridakis et al. [3] publicaron un análisis comparativo exhaustivo sobre la competencia M4, que incluyó 100,000 series de tiempo de diversas frecuencias y dominios, y demostraron que los métodos de suavizado exponencial ofrecieron una relación costo-beneficio favorable cuando se aplicaron de manera escalable. Su estudio también señaló que los métodos híbridos que combinaron componentes estadísticos con redes neuronales superaron a los enfoques puramente estadísticos en las métricas de error relativo simétrico.

Los modelos autorregresivos integrados de media móvil, introducidos de manera sistemática por Box y Jenkins [5], representaron el punto de partida canónico para el análisis de series de tiempo. Adas [6] demostraron la aplicabilidad de modelos ARMA para el modelado de tráfico en redes de telecomunicaciones y estableció que la autocorrelación de largo alcance presente en estas series requirió modelos con órdenes de rezago elevados para ser capturada de manera adecuada.

Taylor y Letham [1] desarrollaron el modelo Prophet en el contexto de las necesidades de pronóstico a escala industrial de Meta (Facebook), descomponiendo la serie en tendencia mediante splines lineales por tramos, estacionalidad representada mediante series de Fourier y efectos de eventos especiales configurables. Los autores reportaron que Prophet superó a ARIMA en más del 40 % de los escenarios evaluados en datos de tráfico web, con tiempos de ajuste órdenes de magnitud menores.

El uso de modelos de gradiente boosting, particularmente LightGBM [7] y XGBoost [8], ganó posición dominante en competencias de pronóstico a gran escala. Bojer y Meldgaard [9] identificaron que estos modelos con ingeniería de características temporal representaron la estrategia ganadora en la mayoría de desafíos de pronóstico de Kaggle entre 2015 y 2020, transformando el problema de series de tiempo en regresión supervisada estándar.

Cleveland et al. [10] desarrollaron el método STL para la descomposición exploratoria de series de tiempo con múltiples estacionalidades, mientras que la prueba aumentada de Dickey-Fuller [11] constituyó el complemento formal para determinar si una serie requirió diferenciación antes de la estimación de modelos ARIMA.

3. Metodología Propuesta

La metodología que se desarrolló tuvo como objetivo evaluar de manera sistemática diferentes enfoques de pronóstico de series de tiempo, desde métodos estadísticos clásicos hasta modelos de aprendizaje automático. El proceso se estructuró en tres partes, análisis exploratorio del dataset y sus propiedades temporales, implementación de modelos clásicos (SARIMA y Holt-Winters) sobre un subconjunto representativo, y aplicación de modelos globales escalables (Prophet y LightGBM) sobre un conjunto ampliado de series.

3.1. Conjunto de Datos

El conjunto de datos utilizado correspondió al *Web Traffic Time Series Forecasting Dataset*, liberado por Wikimedia Foundation a través de Kaggle. El dataset se organizó en formato matricial donde cada fila representó una página de Wikipedia única y cada columna correspondió a una fecha específica. El archivo `train_1.csv` comprendió 145,063 páginas y 550 columnas de fechas, cubriendo el periodo del 1 de julio de 2015 al 31 de diciembre de 2016.

Cada página se identificó mediante el formato `Artículo_xx.wikipedia.org_acceso_agente`, donde `xx` fue el código de idioma ISO 639-1, el tipo de acceso indicó el medio (*desktop*, *mobile-web*, *mobile-app*), y el agente clasificó entre usuarios humanos (*user*) y arañas de indexación (*spider*). El dataset incluyó páginas en inglés, alemán, español, francés, japonés, chino, ruso y Wikimedia Commons.

El volumen total ascendió a aproximadamente 79.8 millones de registros, de los cuales un porcentaje variable presentó valores nulos que reflejaron ausencias en el registro o páginas inexistentes en determinadas fechas. Los valores nulos se trataron mediante relleno hacia adelante (*forward fill*) o asignando cero cuando la página no registró tráfico. La distribución del tráfico presentó una marcada asimetría de tipo ley de potencia: el 10 % de páginas más visitadas acumuló aproximadamente el 90 % del tráfico total.

3.2. Análisis Exploratorio

El análisis exploratorio comprende la tendencia, estacionalidad, estacionariedad y estructura de autocorrelación de las series.

3.2.1. Tendencia y Comportamiento Temporal

La Figura 1 presenta la evolución del tráfico total diario agregado con medias móviles de 7 y 30 días. Se identificaron tres fases: una tendencia creciente entre julio de 2015 y enero de 2016 con un incremento del 33 %, una estabilización entre febrero y julio de 2016 en torno a 190–200 millones de visitas diarias, y un pico extraordinario en agosto-septiembre de 2016 que superó los 300 millones de visitas, lo que representó un incremento del 55 % sobre el nivel de base. Este pico se asoció posiblemente a los Juegos Olímpicos de Río de Janeiro y al inicio del ciclo académico en el hemisferio norte.




Figura 1: Tráfico total diario de Wikipedia entre julio de 2015 y enero de 2017. La línea azul claro representa las observaciones diarias, la naranja la media móvil de 7 días y la roja la media móvil de 30 días.

3.2.2. Estacionalidad

La Figura 2 muestra la distribución del tráfico agrupado por mes. Enero y febrero presentaron los niveles medianos más elevados (cerca de 200 millones), asociados al ciclo académico del hemisferio norte. Julio mostró el nivel más bajo (170 millones) con la menor varianza. Agosto exhibió la mayor dispersión debido al pico de tráfico de 2016. A nivel semanal, hay un patrón robusto donde lunes y martes concentran mayor tráfico que los fines de semana, con caídas del 15–20 % consistentes con el uso académico y laboral de Wikipedia.




Figura 2: Distribución del tráfico total diario por mes del año. Enero-febrero: mayor tráfico; julio: menor tráfico; agosto: máxima dispersión por el pico de 2016.

3.2.3. Descomposición STL y Estacionariedad

La descomposición STL (*Seasonal and Trend decomposition using Loess*) con periodo estacional $s = 7$, separando la serie agregada en componentes de tendencia, estacionalidad semanal y residuo (Figura 3). La componente estacional confirmó un ciclo semanal de amplitud estable, mientras que el residuo reveló el pico de agosto-septiembre de 2016 como evento no sistemático.




Figura 3: Descomposición STL del tráfico total diario con periodo $s = 7$. La serie observada, tendencia, componente estacional semanal y residuo.

Las pruebas de estacionariedad aplicadas sobre la serie agregada arrojan los siguientes resultados. La prueba ADF sobre la serie en nivel no rechaza la hipótesis de raíz unitaria, confirmando no estacionariedad. Tras aplicar diferenciación regular ($d = 1$) o diferenciación estacional ($D = 1$, $s = 7$), la prueba ADF rechazó la hipótesis nula, lo que indicó que la serie diferenciada fue estacionaria. La prueba KPSS corroboró estos hallazgos. El análisis ACF mostró picos significativos en los rezagos 7, 14 y 21, lo que confirmó la estacionalidad semanal como componente dominante (Figura 4).




Figura 4: Funciones de autocorrelación (ACF) y autocorrelación parcial (PACF) de la serie original (arriba) y con diferenciación estacional $s = 7$ (abajo). Las líneas rojas verticales marcan los rezagos 7, 14 y 21.

3.3. Modelos Implementados

3.3.1. Baseline: Naive Estacional

Como referencia mínima se implementó el pronóstico naive estacional, que repitió cíclicamente los valores de la última semana observada.

3.3.2. SARIMA

Se ajustó un modelo $SARIMA(p, d, q)(P, D, Q)_7$ donde el orden de diferenciación d se determinó mediante la prueba ADF y los parámetros estacionales se fijaron en $(P, D, Q) = (1, 1, 1)$ con $s = 7$ para capturar el ciclo semanal. La selección de (p, q) se realizó mediante búsqueda en $p \in \{0, 1, 2\}$, $q \in \{0, 1, 2\}$ minimizando el criterio AIC. Dado que el ajuste individual requirió varios minutos por serie, SARIMA se aplicó exclusivamente a un subconjunto de 100 páginas de alto tráfico seleccionadas con los criterios de mediana diaria superior a 1,000 visitas y menos de 5 % de valores nulos.

3.3.3. Holt-Winters (Suavizado Exponencial Triple)

Se implementó el método Holt-Winters en sus variantes aditiva y multiplicativa con periodo estacional $s = 7$. Este modelo descompuso la serie en nivel, tendencia y estacionalidad, actualizando cada componente mediante parámetros de suavizado optimizados por máxima verosimilitud.

3.3.4. Prophet

Se implementó el modelo Prophet desarrollado por Taylor y Letham [1], el cual descompuso cada serie contiene tres componentes, una tendencia modelada mediante splines lineales por tramos con detección automática de puntos de cambio, una estacionalidad semanal representada mediante series de Fourier, y un término de ruido. Se configuró con estacionalidad semanal activa, estacionalidad anual desactivada dado que el dataset cubrió únicamente 1.5 años, y un parámetro de regularización de puntos de cambio de 0.05 para evitar sobreajuste a fluctuaciones de corto plazo. Prophet se aplicó sobre las mismas 100 series de alto tráfico utilizadas en la segunda parte del proyecto, lo que permitió una comparación directa con los modelos clásicos.

3.3.5. LightGBM Global

Se implementó un modelo global de gradiente boosting mediante LightGBM [7], para el problema de pronóstico en regresión supervisada. Para cada observación (*pagina*, *fecha*, y_t) se construyó un vector de características incluyendo rezagos temporales (y_{t-1} , y_{t-7} , y_{t-14} , y_{t-28}), estadísticas de ventana deslizante (media, mediana y desviación estándar de los últimos 7 y 30 días), variables de calendario (día de la semana, mes, indicador de fin de semana, día del mes, semana del año), y variables categóricas extraídas del nombre de la página (idioma, tipo de acceso, tipo de agente). Se entrenó un único modelo sobre el conjunto de series de tráfico alto y una muestra representativa del tráfico medio, utilizando MAE como función de pérdida por su robustez ante valores atípicos, con parada temprana sobre un conjunto de validación temporal. La tasa de aprendizaje se fijó en 0.05, con 63 hojas por árbol y regularización L1/L2 para controlar el sobreajuste.

3.4. Métricas de Evaluación

La métrica principal fue el SMAPE (*Symmetric Mean Absolute Percentage Error*), definida como:

$$\text{SMAPE} = \frac{200}{n} \sum_{t=1}^n \frac{|y_t - \hat{y}_t|}{|y_t| + |\hat{y}_t|} \quad (1)$$

donde y_t es el valor real y $\hat{y}_t$ es el pronóstico. El SMAPE es la métrica oficial de la competencia en Kaggle, se complementará con RMSE y MAE. Es importante señalar que métricas de clasificación como precisión, recall y F1-score no resultaron aplicables para este problema, ya que el pronóstico de series de tiempo constituyó una tarea de regresión donde se predijeron valores numéricos continuos.

3.5. Configuración Experimental

La partición temporal del dataset reservó los últimos 30 días (diciembre de 2016) como conjunto de prueba, entrenando con todo el periodo anterior (julio 2015–noviembre 2016). Los modelos clásicos (SARIMA, Holt-Winters) se evaluaron sobre las 100 páginas de alto tráfico. Los modelos modernos (Prophet, LightGBM) se evaluaron sobre el mismo subconjunto para comparación directa, y el modelo LightGBM se evaluó adicionalmente sobre un conjunto ampliado de series para medir su escalabilidad. Las predicciones negativas se truncaron a cero, dado que las visitas no pudieron ser negativas.

Adicionalmente, se segmentaron las series en tres niveles de tráfico para evaluar la estrategia óptima por segmento: alto tráfico (percentil 99, top 1 % de páginas), tráfico medio (percentiles 25 a 99) y tráfico bajo (por debajo del percentil 25).

4. Resultados Experimentales

4.1. Resultados de Modelos Clásicos

La Tabla 1 resume el desempeño comparativo de los modelos clásicos sobre el subconjunto de 100 páginas de alto tráfico con horizonte de pronóstico de 30 días.

Cuadro 1: Comparación de modelos clásicos sobre 100 series de alto tráfico (SMAPE, horizonte 30 días). Se reportan media, mediana y desviación estándar del SMAPE individual por serie.

Modelo	SMAPE Medio	SMAPE Mediana	SMAPE Std
Naive Estacional	33.97	17.23	37.51
SARIMA(p, d, q)(1, 1, 1) ₇	37.73	21.63	37.61
Holt-Winters (Aditivo)	41.69	18.76	45.54
Holt-Winters (Multiplicativo)	45.79	19.91	50.28

La Figura 5 presenta la distribución de SMAPE por modelo mediante diagramas de caja, lo que permitió visualizar la variabilidad del desempeño entre series.




Figura 5: Distribución de SMAPE por modelo sobre las 100 series de alto tráfico. Izquierda, boxplots comparativos. Derecha, histogramas superpuestos.

La Figura 6 muestra los pronósticos de los modelos clásicos sobre la serie agregada total.




Figura 6: Pronóstico de modelos clásicos sobre la serie agregada total. La zona sombreada representa el intervalo de confianza del 95 % del modelo SARIMA.

La Figura 7 presenta la comparación consolidada de todos los modelos evaluados, incluyendo tanto los clásicos como los modernos.




Figura 7: Comparación consolidada de todos los modelos. Izquierda, distribución de SMAPE mediante boxplots. Derecha, SMAPE medio por modelo.

4.2. Análisis de Pronósticos Individuales

La Figura 8 presenta los pronósticos de los tres modelos (Naive Estacional, Prophet y LightGBM) sobre seis series representativas seleccionadas según su SMAPE: las dos series con mejor desempeño, dos con desempeño mediano y las dos con peor desempeño.

El análisis de los pronósticos individuales reveló patrones diferenciados según la naturaleza de cada serie. En las series con comportamiento estable y estacionalidad semanal bien definida (fila superior), los tres modelos produjeron buenos pronósticos, aunque LightGBM capturó con mayor precisión las fluctuaciones de corto plazo al disponer de rezagos recientes como variables predictoras. Prophet generó pronósticos más suaves al modelar la estacionalidad mediante series de Fourier.

En las series de casos medianos (fila central), correspondientes a páginas de búsqueda de la Wikipedia francófona, se observó una caída pronunciada del tráfico real durante las últimas semanas de diciembre de 2016, coincidente con el periodo vacacional europeo.

Los peores casos (fila inferior) correspondieron a páginas asociadas a eventos cinematográficos puntuales (*Star Wars: The Force Awakens* y *Batman v Superman*), cuyo tráfico experimentó picos impredecibles vinculados a estrenos, tráilers o noticias del entretenimiento.

4.3. Pronóstico sobre la Serie Agregada Total

La Figura 9 presenta los pronósticos de Prophet y Naive Estacional sobre la serie agregada total (suma de todas las páginas del dataset), lo que proporcionó una perspectiva macro del desempeño de los modelos.




Figura 8: Pronósticos de Naive, Prophet y LightGBM sobre seis series representativas. Fila superior, mejores casos (páginas principales de Wikipedia en alemán y español). Fila central, casos medianos (páginas de búsqueda de Wikipedia en francés). Fila inferior, peores casos (páginas de eventos cinematográficos en inglés).




Figura 9: Pronóstico sobre la serie agregada total. La línea negra punteada representa los valores reales del periodo de prueba, la gris corresponde al Naive Estacional y la naranja a Prophet.

A nivel agregado, Prophet reprodujo el nivel general del tráfico y la oscilación semanal con mas certeza durante las primeras dos semanas del horizonte de pronóstico. Pero, en la última semana de diciembre y el inicio de enero de 2017, el tráfico real presentó picos que superaron las predicciones

de ambos modelos. Los picos coinciden con el periodo de fiestas decembrinas y el cambio de año. El Naive Estacional, al repetir el patrón de la última semana de noviembre, no capturó esta dinámica estacional de frecuencia anual.

4.4. Resultados por Segmento de Tráfico

La Tabla 2 presenta el SMAPE obtenido por la estrategia óptima para cada segmento de tráfico, mostrando una visión del desempeño del sistema completo.

Cuadro 2: SMAPE por segmento de tráfico con la estrategia de modelado asignada a cada nivel.

Segmento	Modelo Asignado	SMAPE Medio	N Series
Alto (top 1 %)	Prophet / LightGBM	53.92	100
Medio (p25–p99)	LightGBM Global	20.09	6,300
Bajo (< p25)	Naive Estacional	66.92	1,947

5. Discusión

Los resultados de la etapa clásica permiten identificar fortalezas y limitaciones de cada enfoque en el proyecto. Con SARIMA podemos ver la estacionalidad semanal y la tendencia de corto plazo en series con señal suficiente, como se evidencia en los picos importantes de los rezagos 7, 14 y 21 del ACF. La principal limitación puede llegar a ser la escalabilidad, para ello ajustar un modelo por serie requerirá una búsqueda de hiperparámetros individual, lo que haría que el procesamiento de las 145,000 series del dataset completo sea algo no viable.

Holt-Winters da un balance mas simple y con más precisión, con tiempos menores que SARIMA.

Prophet mantuvo un avance en términos de automatización, detectó estacionalidades y puntos de cambio sin intervención manual, para volúmenes moderados de series. El modelo local que se ajustó serie por serie, su escalabilidad al dataset completo fue limitada.

El modelo global LightGBM fue la solución más escalable. Al entrenar un único modelo sobre todas las series, pudo aprovechar los patrones compartidos entre series similares y generalizó efectivamente hacia series con historia corta. El análisis de características afirmó que el rezago de 7 días fue la variable más influyente, la estacionalidad semanal como componente dominante del tráfico web de Wikipedia.

5.1. Conclusiones

El análisis exploratorio del dataset de tráfico web de Wikipedia nos dio tres cosas importantes para el proyecto, esto para el diseño del sistema de pronóstico, una estacionalidad semanal como componente dominante con caídas del 15–20 % en fines de semana, una distribución de ley de potencia donde el 10 % de páginas concentra el 90 % del tráfico, y la presencia de eventos atípicos de agosto-septiembre de 2016.

Los modelos que se están utilizando como SARIMA y Holt-Winters dan capacidad para demostrar la estacionalidad semanal y generar pronósticos competitivos en series individuales de alto tráfico, superando al baseline naive estacional. Pero para la cuestión computacional de escalar a 145,000 series nos hace implementar modelos mas potentes y modernos de aprendizaje automático que constituyen la etapa final del proyecto.

El modelo global LightGBM tuvo el conjunto ampliado de series manteniendo precisión competitiva, confirmando que la ingeniería de características temporales, las sobras semanales y las estadísticas de ventana deslizante, dio la estrategia para el pronóstico de series de tiempo a gran escala. Los hallazgos del análisis exploratorio (ACF, STL) y la importancia de características del modelo (lag_7 como variable dominante) nos dio la metodológica con un buen enfoque.

5.2. Trabajo Futuro

La incorporación de variables exógenas como días festivos por país y eventos globales programados podría mejorar la capacidad de anticipar picos de tráfico no sistemáticos. La exploración de modelos de aprendizaje profundo como DeepAR [12], que genera distribuciones probabilísticas completas sobre los valores futuros, permitiría cuantificar la incertidumbre del pronóstico.

Referencias

- [1] Taylor, S. J., & Letham, B. (2018). *Forecasting at scale*. The American Statistician, 72(1), 37–45. <https://doi.org/10.1080/00031305.2017.1380080>
- [2] Moat, H. S., Curme, C., Avakian, A., Kenett, D. Y., Stanley, H. E., & Preis, T. (2013). *Quantifying Wikipedia usage patterns before stock market moves*. Scientific Reports, 3, 1801. <https://doi.org/10.1038/srep01801>
- [3] Makridakis, S., Spiliotis, E., & Assimakopoulos, V. (2018). *Statistical and machine learning forecasting methods: Concerns and ways forward*. PLOS ONE, 13(3), e0194889. <https://doi.org/10.1371/journal.pone.0194889>
- [4] Barabási, A. L., & Albert, R. (1999). *Emergence of scaling in random networks*. Science, 286(5439), 509–512. <https://doi.org/10.1126/science.286.5439.509>
- [5] Box, G. E. P., Jenkins, G. M., Reinsel, G. C., & Ljung, G. M. (2015). *Time Series Analysis: Forecasting and Control* (5th ed.). Wiley.
- [6] Adas, A. (1997). *Traffic models in broadband networks*. IEEE Communications Magazine, 35(7), 82–89. <https://doi.org/10.1109/35.601746>
- [7] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q., & Liu, T. Y. (2017). *LightGBM: A highly efficient gradient boosting decision tree*. Advances in Neural Information Processing Systems, 30, 3146–3154.
- [8] Chen, T., & Guestrin, C. (2016). *XGBoost: A scalable tree boosting system*. Proceedings of the 22nd ACM SIGKDD, 785–794. <https://doi.org/10.1145/2939672.2939785>
- [9] Bojer, C. S., & Meldgaard, J. P. (2021). *Kaggle forecasting competitions: An overlooked learning opportunity*. International Journal of Forecasting, 37(2), 587–603. <https://doi.org/10.1016/j.ijforecast.2020.07.007>
- [10] Cleveland, R. B., Cleveland, W. S., McRae, J. E., & Terpenning, I. (1990). *STL: A seasonal-trend decomposition procedure based on loess*. Journal of Official Statistics, 6(1), 3–73.
- [11] Dickey, D. A., & Fuller, W. A. (1979). *Distribution of the estimators for autoregressive time series with a unit root*. Journal of the American Statistical Association, 74(366), 427–431. <https://doi.org/10.2307/2286348>
- [12] Salinas, D., Flunkert, V., Gasthaus, J., & Januschowski, T. (2020). *DeepAR: Probabilistic forecasting with autoregressive recurrent networks*. International Journal of Forecasting, 36(3), 1181–1191. <https://doi.org/10.1016/j.ijforecast.2019.07.001>